


» familiär, praxisnah,
chancenreich und
topaktuell «

informatik
medizin-informatik



DSAI: Ethik und KI

Unfaire und Vertrauenswürdige KI



Es gibt viele Möglichkeiten, wie eine KI “unfair” sein kann. Beispiele dafür sind zum Beispiel:

- AMS-Algorithmus
- Gesichtserkennung
- “Stereotypisierung”
- ...

Wir betrachten nun

- Details und Ursprung dieser Problematiken
- Definition von “unfair”
- Verringerung der Unfairness und Verwendung vertrauenswürdiger KI’s.

- **Bias** ist übersetzt **Voreingenommenheit**.
- Die meisten KI-Systeme sind standardmäßig biased, das heißt die meisten KI-Systeme sind von Natur aus nicht neutral/fair.
- Das passiert nicht absichtlich, sondern hängt stark mit den Trainingsdaten zusammen. Wir unterscheiden zwischen **expliziten** und **impliziten** Bias.
- Der **Bias** ist also das, was wir bei einer KI als **unfair** bezeichnen!

- Sichtbar im Dataset
- Beispiele:
 - ▶ Gewisse Werte der Features (Geschlecht, Herkunft, etc.) kommen öfter vor als andere.
 - ▶ Autofokus Kamera: Dunkelhäutige Personen werden oft schlechter (weniger oft) erkannt.

- Oft in Daten versteckt
- Beispiele:
 - ▶ Postleitzahl als Stellvertreter für soziale Herkunft
 - ▶ Stereotypen bei Language Models oder auch Bild/Video generierenden Modellen (Führungskraft=männlich, Reinigungskraft=weiblich)
- Die Frage ist nun, wie den expliziten und impliziten Bias verringern können.

■ Mehrere Möglichkeiten:

- ▶ Sensible Features entfernen
- ▶ Unterrepräsentierte Gruppen stärker gewichten im Loss
- ▶ Resampling: Oversampling benachteiligter Gruppen und/oder Undersampling von dominanten Gruppen

- Schwieriger als Entfernen von explizitem Bias!
- Möglichkeiten:
 - ▶ Entfernen von Features, welche mit sensiblen Features korrelieren. Zum Beispiel Postleitzahl könnte mit Einkommen korrelieren, da die Herkunft auch viel über das Durchschnittsgehalt aussagt.
 - ▶ Bei Generative AI (zBsp.: LLM's oder Bildgenerierung) können Eigenschaften wie Geschlecht usw. aus dem Text entfernt werden. Also Frau→Person und Mann→Person.
 - ▶ weitere (komplizierte) Möglichkeiten, welche stark von dem Task abhängen.

- Quantifizieren von Bias notwendig, insbesondere für Reduzierungstechniken.
- Messen von Bias, je nach vorliegendem Bias schwierig.
- Explizit:
 - ▶ Feature-Importance für Entscheidungsfindung
 - ▶ Bei **einfachen** neuronalen Netzen zBsp. die finale Funktion anzeigen lassen.
- Implizit:
 - ▶ Sehr subjektiv
 - ▶ Testen, wie oft ein Model Output der Form X und Output der Form Y produziert.
 - ▶ Beispiele:
 - Testen, wie oft ein Modell bei gleichen Bewerbungsunterlagen einen Mann bevorzugt im Vergleich zu einer Frau.
 - Testen, wie oft beim Bildgenerieren mit speziellem Prompt (zBsp. Person mit Pflegeberuf) ein Mann bzw. eine Frau generiert wird.
- Wir wollen nun noch die Stereotypisierung extra betrachten.

Motivierendes Beispiel: www.youtube.com.

- Viele Inhalte, welche von KI's generiert werden beinhalten **Stereotypen**, also Vorurteile, welche sich bei uns leider auch oft in der Gesellschaft etabliert haben.
- Als Beispiel betrachten wir nun auch den folgenden Artikel von Bloomberg: www.bloomberg.com
- Wie lassen sich vielleicht unsere gesellschaftlichen Vorurteile, welche auch in dem Bloomberg Artikel sehen, zusammen fassen?

- Ein zu starkes “Debiasing” kann zu (sehr) falschen Ergebnissen führen.
- **Beispiel:** Gemini 2024: Extreme Falschinformationen bei Bildgenerierung: [Link1](#), [Link2](#)
- Ein weiteres interessantes Beispiel/Phänomen: [Link3](#)

- In kritischen Bereichen: **Vertrauenswürdige KI** (=Trustworthy AI) notwendig, um Vertrauen zu schaffen.
- Was sind kritische Beispiele? (Medizin, wichtige Entscheidungsfindung, etc.)
- Wann vertrauen wir einer KI?
- Eine Möglichkeit: **Explainable AI**.

- Soll Auskunft/Informationen geben, **wie eine KI zu einer Entscheidung kam.**
- Kann auf verschiedene Wege passieren.
- **Beispiel:** <https://jku-vds-lab.at/hoxai/>
- **Beispiel:** AMS-Algorithmus sagt, man ist für Jobmarket eher ungeeignet.
- **Beispiel:** RAG System erklärt, wie es zu einer Entscheidung gekommen ist, indem es Referenzen zur Knowledge-Base angibt.
- **Beispiel:** Grad-CAM für Bildklassifizierung.
www.datascientest.com